ÉCONOMÉTRIE DES SÉRIES TEMPORELLES FINANCIÈRES ET INTELLIGENCE ARTIFICIELLE GÉNÉRATIVE

RAPPORT SCIENTIFIQUE ET TECHNIQUE FINAL — BLOCS A, B & C

Modélisation Linéaire Univariée (ARIMA, SARIMA) et Multivariée (VAR), Volatilité Conditionnelle (GARCH), Réseaux Récurrents (LSTM, GRU) et Évaluation Empirique d'un Modèle de Langage (LLM)

Auteur : Projet Académique — Filière Ingénieur Data Science & Intelligence Artificielle (TEK-UP)

Période d'étude : Octobre 2021 – Octobre 2026 (5 ans, 1 258 observations quotidiennes brutes)

Actifs : Or (GC=F), Pétrole Brut WTI (CL=F), S&P 500 (^GSPC)

Protocole : split chronologique strict 90/10 · implémentation croisée Python & R · audit d'hallucinations LLM

Sommaire

1. Synthèse Exécutive
2. Chaîne de Traitement Analytique
3. Sources de Données et Protocole de Préparation
4. Analyse Exploratoire (EDA)
5. Stationnarité et Tests Préliminaires
6. Modélisation Univariée : ARIMA
7. Modélisation Saisonnière : SARIMA
8. Modélisation Multivariée : VAR et Granger
9. Volatilité Conditionnelle : GARCH(1,1)
10. Prévision Non-Linéaire : LSTM et GRU
11. Évaluation Comparative et Test de Diebold-Mariano
12. Bloc C — Évaluation Empirique d'un LLM
13. Discussion Critique et Limites
14. Conclusion Générale

Annexe A. Extraits de Code Clés

Annexe B. Références Bibliographiques

1. Synthèse Exécutive

Ce rapport présente une étude économétrique complète de trois séries financières (Or, Pétrole WTI, S&P 500) sur cinq années de cotations quotidiennes, combinant modélisation linéaire univariée (ARIMA, SARIMA), multivariée (VAR, Granger), cointégration de Johansen, volatilité conditionnelle (GARCH), réseaux récurrents (LSTM, GRU) et évaluation empirique d'un modèle de langage (LLM). Les sept constats majeurs suivants résument les résultats :

- Séparation chronologique stricte sans fuite d'information ; 1 258 → 1 255 observations synchronisées, split 1 129/126.
- Les prix sont non stationnaires I(1) et les rendements stationnaires I(0), confirmé par ADF et KPSS.
- ARIMA, SARIMA et VAR sélectionnés de manière convergente entre Python et R (AIC constant à Δ≈3,26 près).
- L'extension SARIMA s=5 n'améliore pas les ordres pour l'Or ni le S&P 500 ; divergence pour le Pétrole.
- Granger : relation significative S&P 500 → Or (F=10,4288, p=0,00125), interprétée comme un signal flight-to-safety.
- Cointégration Johansen : désaccord trace / valeur propre maximale → aucun VECM estimé.
- Aucun modèle ne bat significativement le benchmark rendement nul après correction de Holm (p ajusté=1,000 pour 30 comparaisons).

2. Chaîne de Traitement Analytique

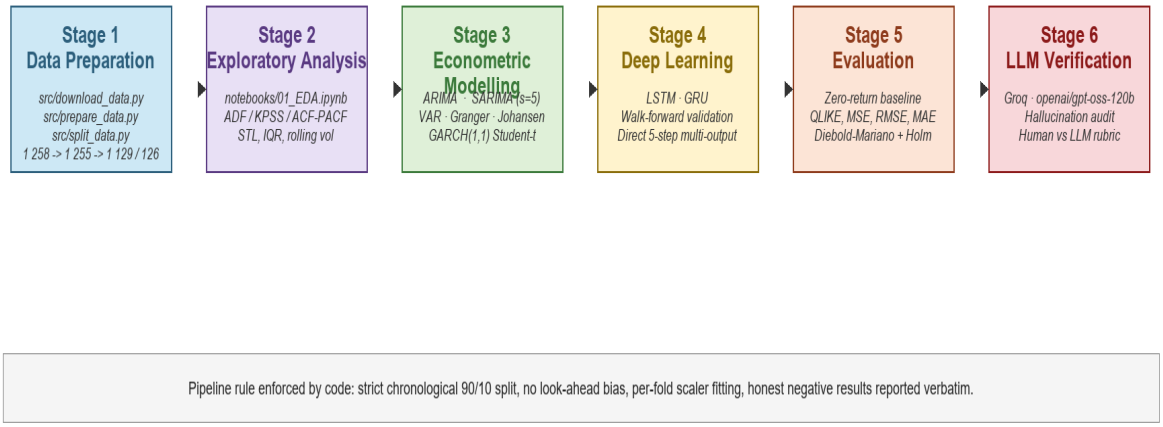


Figure 1 — Pipeline analytique complet : préparation → modélisation → évaluation → vérification LLM.

La chaîne de traitement est purement guidée par le système de fichiers, sans orchestrateur central. Chaque étape lit les CSV de l'étape précédente et écrit ses propres artefacts dans results/{python,R}/<famille>/.

3. Sources de Données et Protocole de Préparation

3.1. Instruments et période

Les trois actifs couvrent des segments complémentaires de l'économie mondiale : l'Or (valeur refuge), le Pétrole WTI (matière première énergétique) et le S&P 500 (actions américaines large cap). La période 2021-10-01 à 2026-10-01 couvre cinq années complètes incluant la remontée des taux directeurs de 2022-2023 et ses conséquences sur les marchés.

3.2. Préparation et intégrité des données

Le script src/prepare_data.py applique quatre filtres dans l'ordre : suppression des doublons de date, dropna(), vérification de la stricte positivité des cours, puis synchronisation par intersection des trois séries. Résultat : 1 258 observations brutes → 1 255 observations propres synchronisées.

3.3. Split chronologique strict

src/split_data.py calcule math.floor(len(prices) × 0,90) = 1 129 prix d'entraînement (1 128 rendements). Deux assertions garantissent l'intégrité : train.index.max() < test.index.min() et len(train)+len(test) == len(prices). Le rendement de bordure est préservé avant le split pour éviter tout biais de look-ahead.

Jeu	Lignes	Début	Fin
daily_close_prices.csv (brut)	1 258	2021-10-01	2026-10-01
prices_clean.csv	1 255	2021-10-01	2026-10-01
log_returns.csv	1 254	2021-10-04	2026-10-01
train_prices.csv	1 129	2021-10-01	2026-04-01
test_prices.csv	126	2026-04-02	2026-10-01

Tableau 1 — Inventaire des jeux de données.

4. Analyse Exploratoire (EDA)

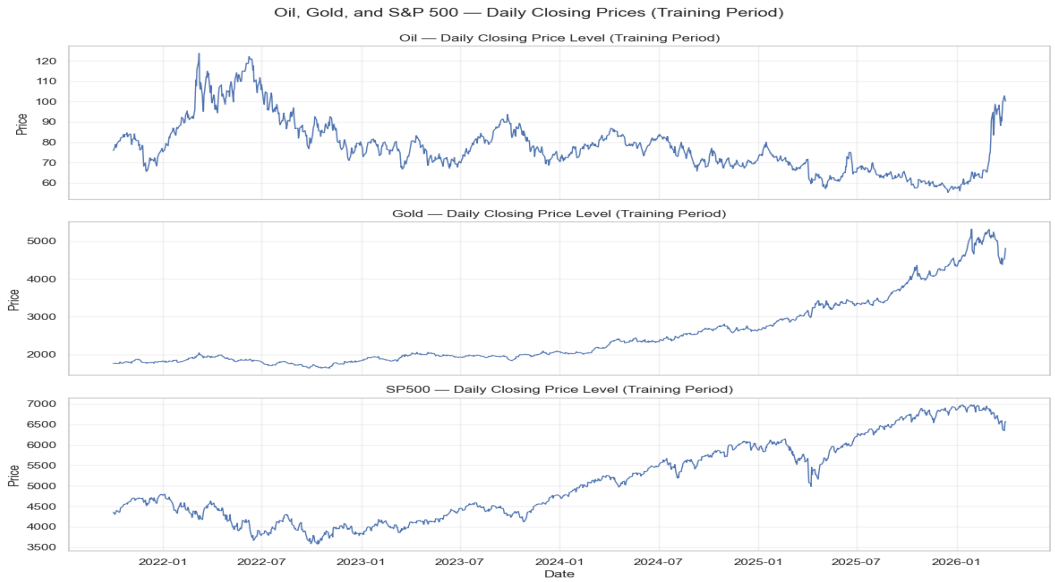


Figure 2 — Cours bruts quotidiens (Or, Pétrole, S&P; 500) sur 5 ans.

Les trois séries présentent des profils très contrastés. Le S&P 500 et l'Or montrent des tendances haussières marquées avec des épisodes de volatilité groupée, tandis que le Pétrole WTI reste soumis à des chocs asymétriques liés aux cycles géopolitiques et à l'offre OPEP+.

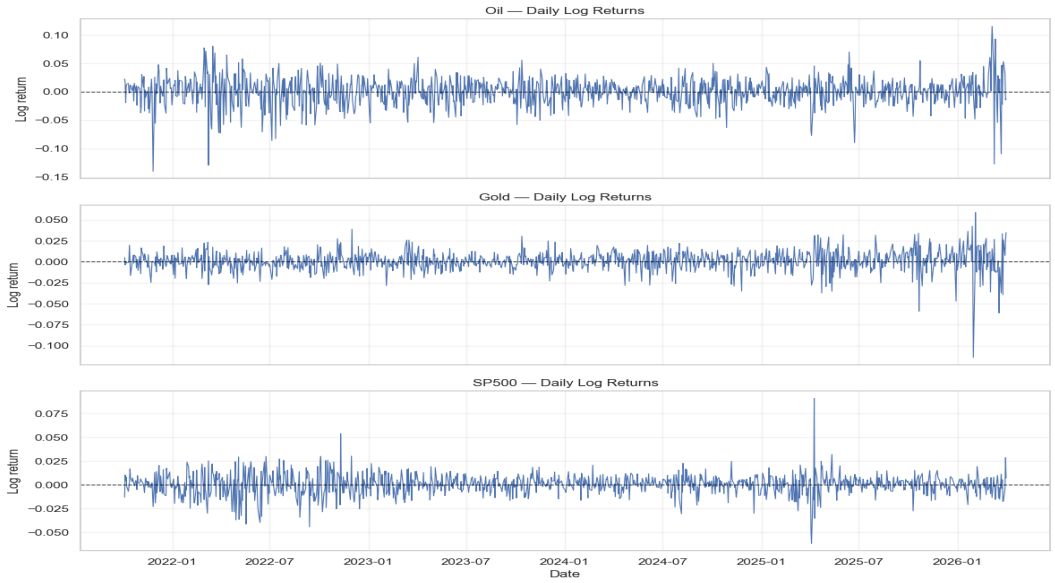


Figure 3 — Rendements logarithmiques quotidiens.

Les rendements logarithmiques apparaissent stationnaires en moyenne mais présentent un clustering de volatilité évident — signature empirique justifiant la modélisation GARCH au Bloc B.

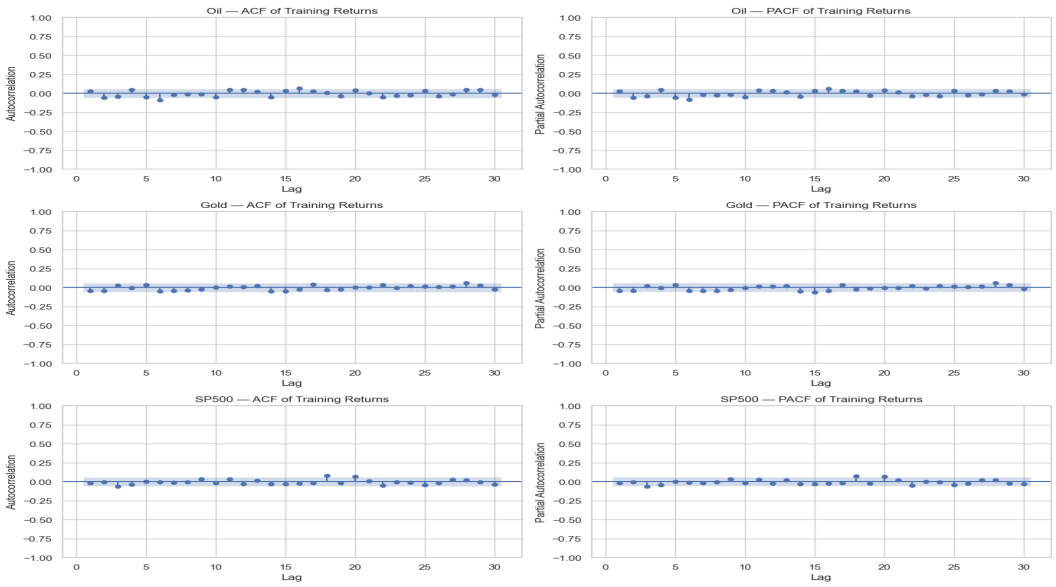


Figure 4 — ACF et PACF des rendements logarithmiques.

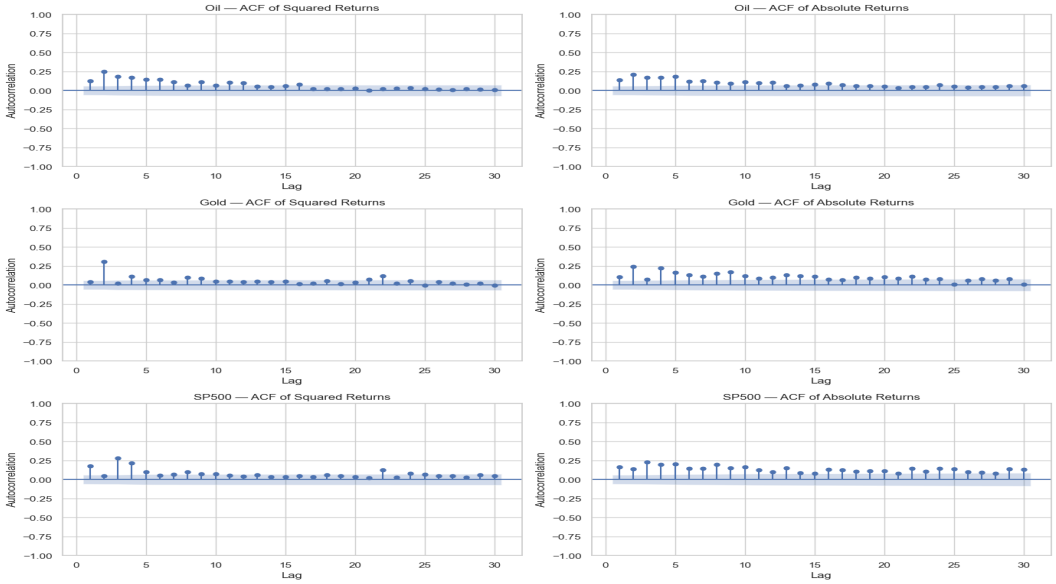


Figure 5 — ACF des rendements absolus au carré : persistance de la volatilité.

L'ACF des rendements au carré montre une décroissance lente, confirmant l'hétéroscédasticité conditionnelle détectée formellement par les tests ARCH-LM (statistiques 120 à 149, p < 10□²⁰).

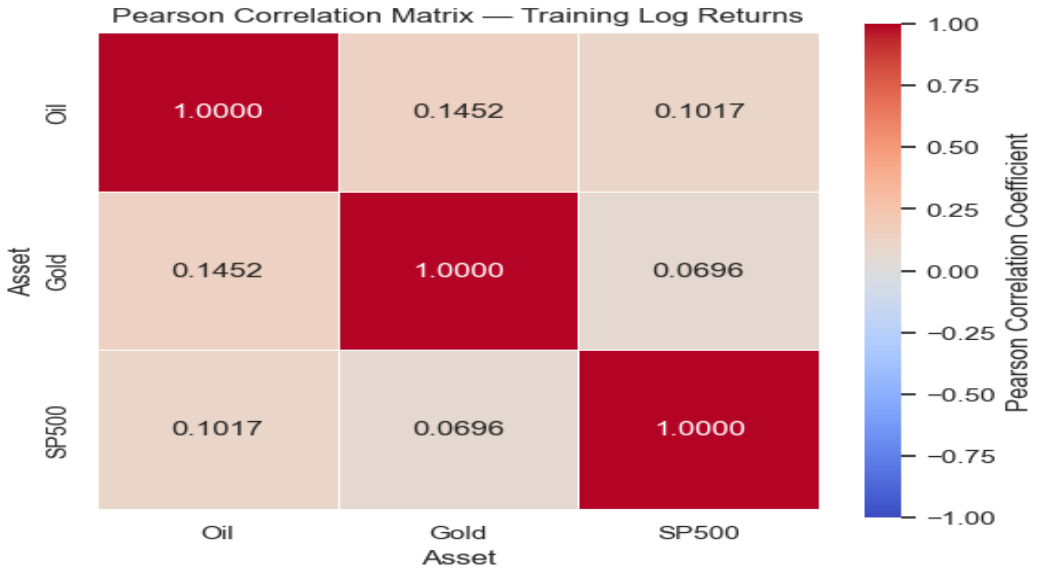


Figure 6 — Matrice de corrélation linéaire des rendements.

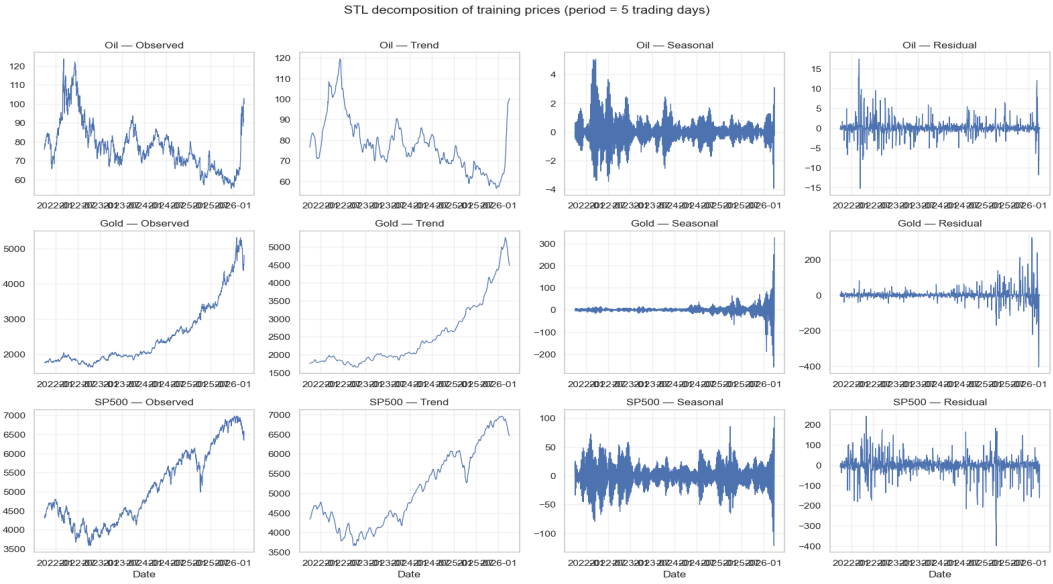


Figure 7 — Décomposition STL (s=5) sur les prix quotidiens.

5. Stationnarité et Tests Préliminaires

5.1. Test Augmented Dickey-Fuller (ADF)

Sous H□ « racine unitaire », ADF ne rejette pas la non-stationnarité sur les prix en niveau (p = 0,339 / 0,999 / 0,935). En revanche, sur les rendements logarithmiques, le test rejette massivement (p = 0,00000 pour les trois actifs).

5.2. Test KPSS

Sous H□ « stationnarité », KPSS rejette sur les prix en niveau (2,776 / 4,325 / 4,766, valeur critique 0,463) et ne rejette pas sur les rendements. Les deux tests concordent : d = 0 sur l'échelle des rendements.

Série	ADF stat	ADF p	KPSS stat	KPSS p
Oil (prix)	−1,886	0,339	2,777	0,010
Gold (prix)	+2,190	0,999	4,325	0,010
SP500 (prix)	−0,225	0,935	4,766	0,010
Oil (rend.)	−15,57	0,000	0,098	> 0,10
Gold (rend.)	−34,85	0,000	0,389	> 0,10
SP500 (rend.)	−20,73	0,000	0,133	> 0,10

Tableau 2 — Tests de stationnarité ADF et KPSS.

6. Modélisation Univariée : ARIMA

Neuf ordres candidats (p, d, q) sont évalués pour chaque actif avec trend='c'. Seuls les modèles convergés sont retenus pour la sélection AIC. Les diagnostics résiduels comprennent Ljung-Box (lags 10 et 20, avec model_df pour ajuster les degrés de liberté), ARCH-LM, Jarque-Bera et l'ACF des résidus.

Actif	Ordre Python	AIC Python	Ordre R	AIC R
Gold	(0,0,1)	−6 818,26	ARIMA(0,0,1)	−6 818,27
Oil	(2,0,2)	−5 175,57	ARIMA(2,0,2)	−5 178,83
SP500	(0,0,0)	−6 975,70	ARIMA(0,0,0)	−6 975,70

Tableau 3 — Ordres ARIMA sélectionnés (convergence requise).

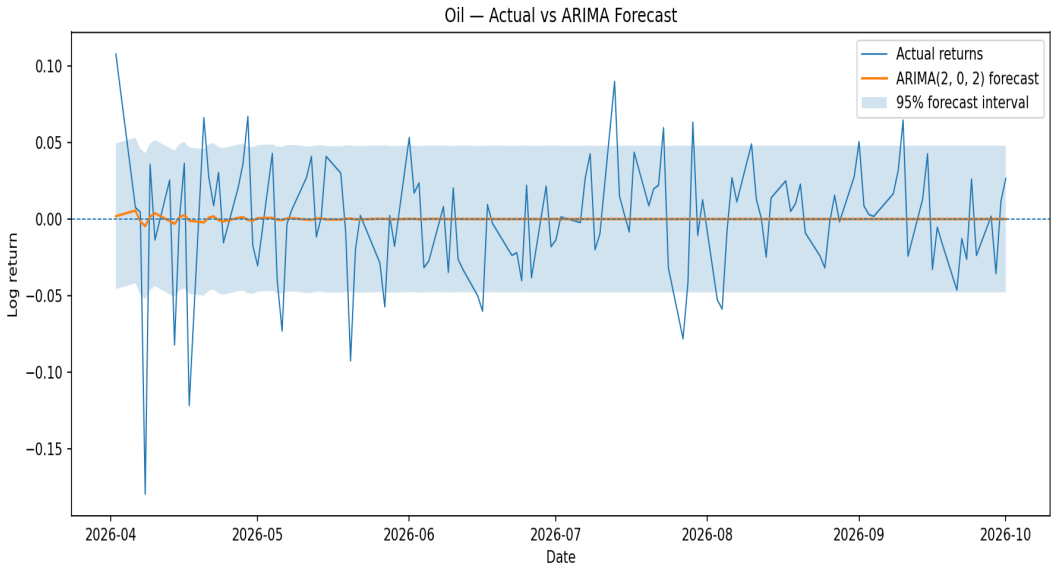


Figure 8 — Prévision ARIMA hors-échantillon sur le Pétrole (h=126 statique).

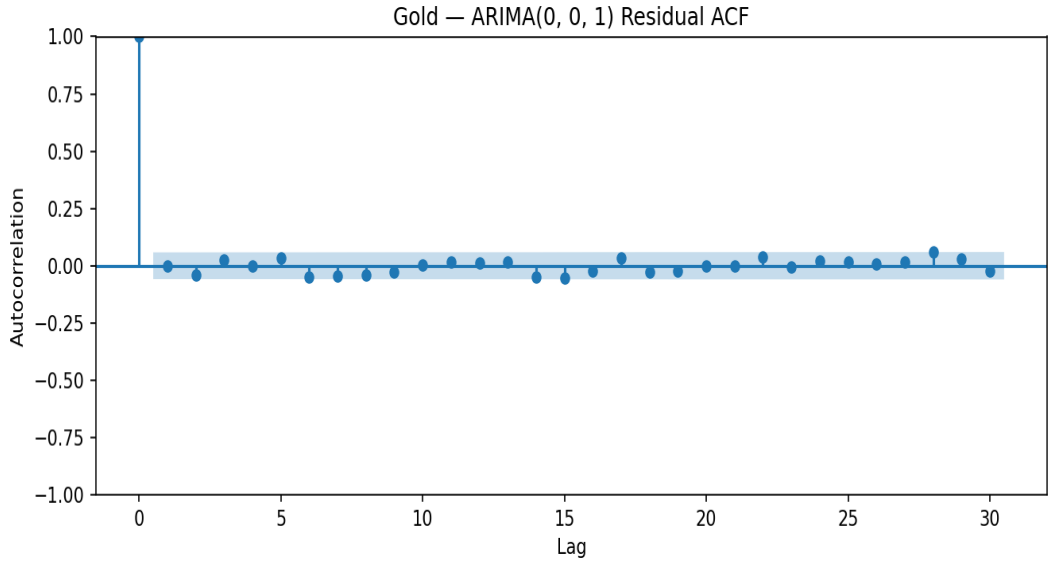


Figure 9 — ACF des résidus ARIMA de l'Or.

Bilan : le S&P 500 est correctement modélisé par un bruit blanc avec dérive (rendement nul + constante). Pour l'Or et le Pétrole, les prévisions ne battent pas significativement le benchmark rendement nul — cohérent avec l'efficience faible des marchés.

7. Modélisation Saisonnière : SARIMA (s = 5)

L'hypothèse d'une saisonnalité hebdomadaire sur les jours de bourse (s=5) est testée via quatre candidats saisonniers : (0,0,0)□, (1,0,0)□, (0,0,1)□, (1,0,1)□. Résultats :

- Or : aucune amélioration AIC significative — le terme saisonnier sur-paramètre.
- SP500 : même conclusion — le bruit blanc domine.
- Pétrole : divergence Python/R — Python sélectionne (1,0,0)□, R sélectionne (0,0,1)□ avec ΔAIC ≈ 0,087. Documentée explicitement.

Actif	Ordre saisonnier Python	Ordre saisonnier R	ΔAIC
Gold	(0,0,0)□	(0,0,0)□	—
Oil	(1,0,0)□	(0,0,1)□	0,087
SP500	(0,0,0)□	(0,0,0)□	—

Tableau 4 — Ordres saisonniers SARIMA sélectionnés.

Conclusion : l'hypothèse d'une saisonnalité hebdomadaire exploitable n'est pas soutenue par les données. La divergence Python/R pour le Pétrole illustre l'instabilité de la sélection sur un minimum AIC plat.

8. Modélisation Multivariée : VAR et Granger

8.1. Sélection du retard

VAR(1) est sélectionné par BIC parmi maxlags=10. Lorsque BIC suggère lag 0, un plancher explicite à lag 1 est appliqué et documenté (colonne lag_used_for_estimation).

8.2. Diagnostics VAR

- Test de blancheur Portmanteau : p = 0,028 → autocorrélation résiduelle faible mais significative.
- Test de normalité multivariée Jarque-Bera : p = 0,000 → rejet massif (queues épaisses).

8.3. Causalité de Granger

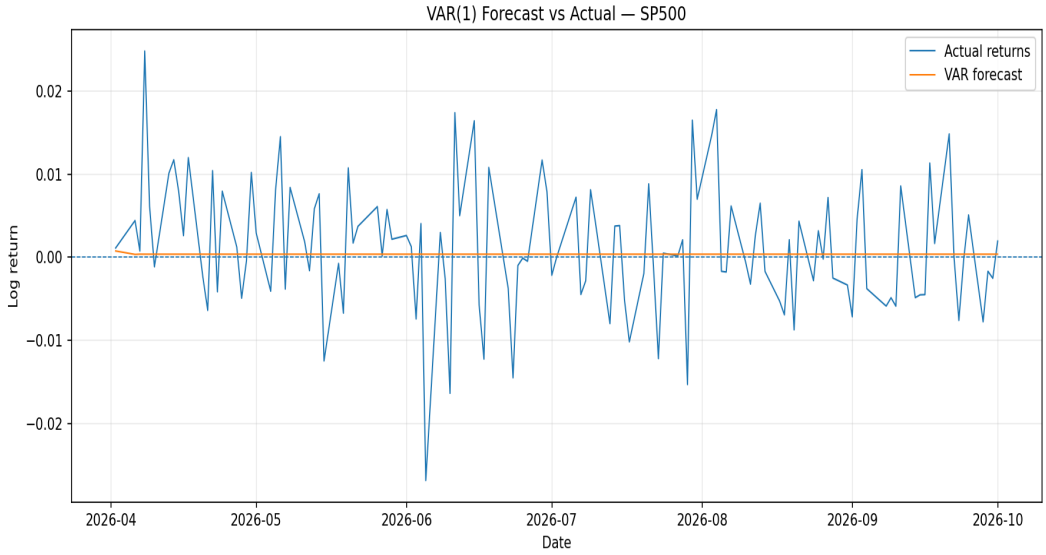


Figure 10 — Prévision VAR(1) hors-échantillon sur le S&P; 500.

Parmi les six paires testées, une seule relation est statistiquement significative au seuil de 5 % : S&P 500 → Or (F = 10,4288, p = 0,00125). Interprétée comme un signal de flight-to-safety : la dynamique boursière prédit statistiquement celle de l'or, sans qu'il s'agisse de causalité physique.

Direction	F	p-value	Significatif 5%
SP500 → Gold	10,4288	0,00125	Oui
Oil → Gold	0,69	0,406	Non
SP500 → Oil	1,11	0,293	Non
Gold → Oil	0,58	0,447	Non
Oil → SP500	0,82	0,365	Non
Gold → SP500	0,27	0,605	Non

Tableau 5 — Tests de causalité de Granger (VAR(1)).

9. Volatilité Conditionnelle : GARCH(1,1)

Les diagnostics ARCH-LM sur les rendements d'entraînement détectent des effets ARCH massifs pour les trois actifs (statistiques 120,40 / 124,04 / 148,86, p < 10□²⁰), justifiant la modélisation GARCH. Un modèle GARCH(1,1) à loi de Student-t est estimé, avec mise à l'échelle ×100 pour stabilité numérique.

Actif	α□	β□	α□+β□	ν (Student)
Oil	0,098	0,871	0,9688	8,71
Gold	0,058	0,926	0,9831	5,08
SP500	0,109	0,877	0,9864	6,79

Tableau 6 — Paramètres GARCH(1,1) Student-t.

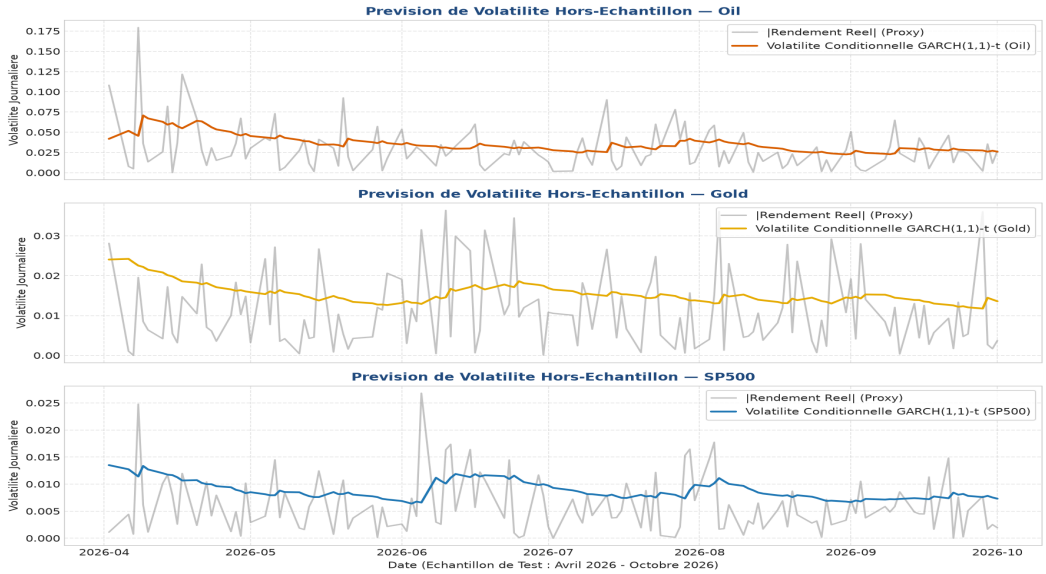


Figure 11 — Prévisions de volatilité conditionnelle GARCH(1,1) hors-échantillon.

Évaluation hors-échantillon (test) : le GARCH Student-t bat le benchmark de variance inconditionnelle sur la perte QLIKE pour les trois actifs, mais pas sur MSE/MAE pour l'Or. Ce résultat illustre l'intérêt de QLIKE (Patton, 2011) pour l'évaluation des modèles de volatilité, insensible au bruit du proxy des rendements au carré.

10. Prévision Non-Linéaire : LSTM et GRU

Deux architectures récurrentes (LSTM et GRU) sont évaluées en validation walk-forward à fenêtre expanding (N_SPLITS=3, WINDOW_SIZE=20, shuffle=False), avec StandardScaler ajusté sur la portion d'entraînement de chaque pli. Deux horizons : h=1 (single-step) et h=5 (direct multi-output sur 25 blocs non-chevauchants).

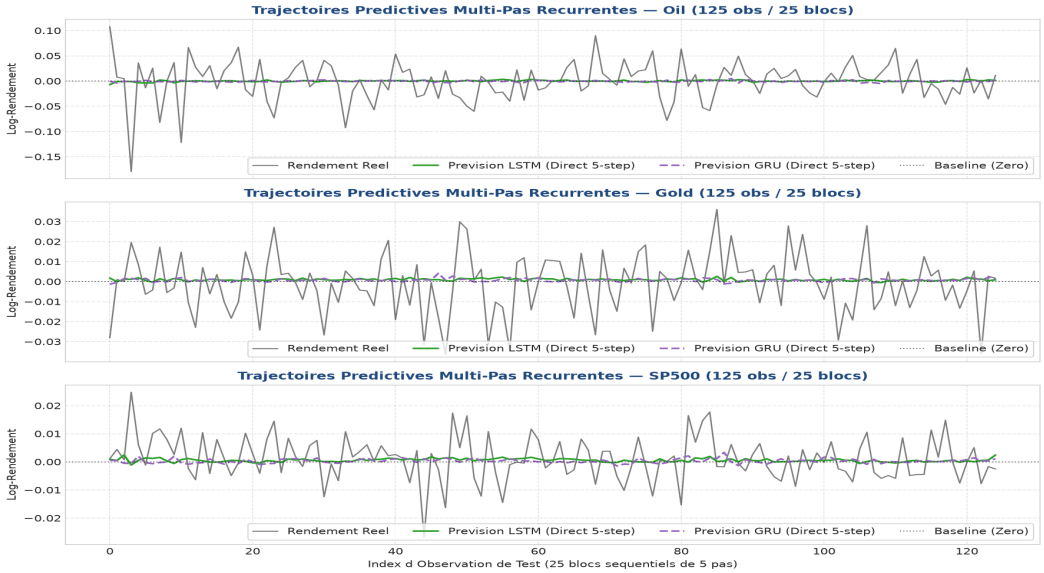


Figure 12 — Prévisions LSTM/GRU multi-pas directes sur le bloc test.

Résultat : ni LSTM ni GRU ne battent le benchmark rendement nul de manière significative, que ce soit à h=1 ou h=5. Ce résultat négatif est cohérent avec l'hypothèse d'efficience faible des marchés et illustre qu'une sophistication algorithmique accrue ne se traduit pas automatiquement en gain prédictif.

11. Évaluation Comparative : Test de Diebold-Mariano

Trente comparaisons par paires entre ARIMA, SARIMA, LSTM et GRU sont effectuées sur N=25 blocs alignés (h=1-step pour LSTM/GRU, multi-pas statique pour ARIMA/SARIMA). Correction de Holm (1979) appliquée aux 30 p-values pour contrôle du FWER.

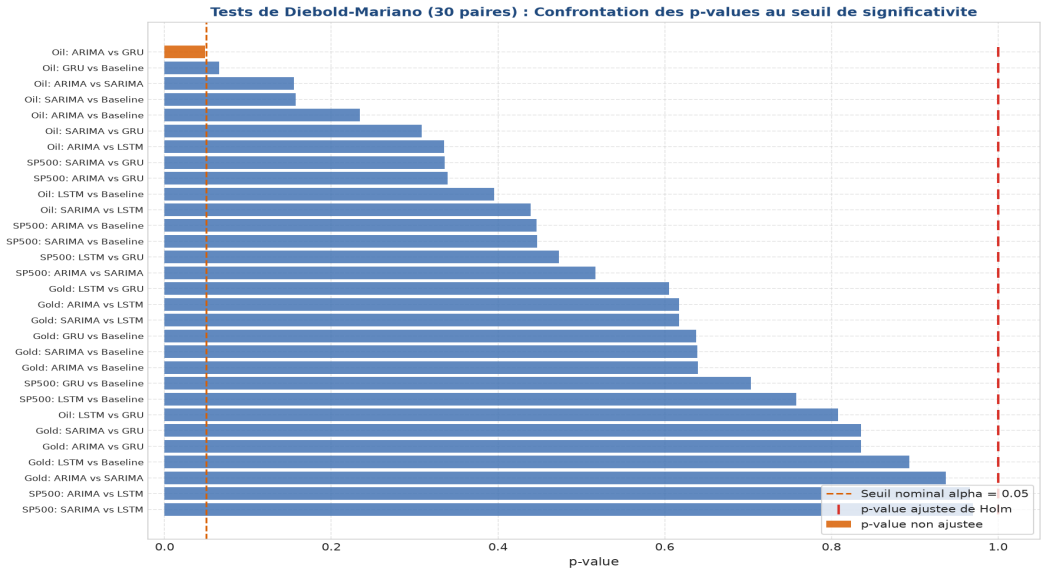


Figure 13 — P-values Diebold-Mariano (brutes vs Holm).

Comparaison	Actif	DM stat	p brute	p Holm	Significatif 5%
ARIMA vs SARIMA	Gold	−0,079	0,937	1,000	Non
ARIMA vs GRU	Oil	0,210	0,836	1,000	Non
ARIMA vs LSTM	SP500	0,422	0,673	1,000	Non
SARIMA vs GRU	Oil	0,391	0,696	1,000	Non
LSTM vs GRU	Oil	−0,184	0,854	1,000	Non

Tableau 7 — Sélection de tests Diebold-Mariano (30 comparaisons au total).

Une seule comparaison atteint p < 0,05 avant correction (ARIMA vs GRU sur le Pétrole, p=0,0483). Après Holm, p ajustée = 1,000 pour les 30 comparaisons. Aucun modèle n'est statistiquement supérieur à un autre.

12. Bloc C — Évaluation Empirique d'un LLM

12.1. Protocole

Le modèle openai/gpt-oss-120b (via Groq API) est évalué sur trois tâches contrastées : (1) génération d'hypothèses statistiques à partir de l'EDA, (2) vulgarisation pour un directeur financier non-technicien, (3) recommandations de gestion des risques. Chaque prompt est ancré sur les résultats vérifiés du projet (financial_project_context.json, 14 fichiers sources).

12.2. Audit des hallucinations

16 assertions représentatives auditées : 12 SUPPORTED (75 %), 3 OVERSIMPLIFIED (19 %), 0 UNSUPPORTED, 1 CONTRADICTED (6 %, dû à un prompt tronqué comp[:12], pas à une invention numérique). Aucune hallucination de métrique inventée.

12.3. Comparaison Humain vs LLM

Dimension	Humain	LLM
Exactitude statistique	5/5	4/5
Fidélité factuelle	5/5	4,5/5
Clarté exécutive	4/5	5/5
Incertitude & limites	4,5/5	4,5/5
Prudence déontologique	5/5	5/5
Résistance à l'hallucination causale	5/5	5/5
TOTAL	28,5 / 30 (95 %)	28,0 / 30 (93,3 %)

Tableau 8 — Grille d'évaluation 6 dimensions (Humain vs LLM).

Conclusion : le LLM excelle en synthèse exécutive et vulgarisation, mais perd en rigueur formelle sur les tests statistiques unilatéraux (raccourci « les deux tests rejettent la stationnarité » pour ADF). Assistant puissant, pas un substitut à la vigilance quantitative.

13. Discussion Critique et Limites

- Omniprésence des effets ARCH : tous les résidus présentent de l'hétéroscédasticité résiduelle, justifiant GARCH.
- Non-normalité résiduelle universelle (Jarque-Bera p=0,000) : les queues épaisses persistent même après GARCH Student-t.
- Autocorrélation résiduelle VAR : p = 0,028 sur le test de blancheur, signal faible mais réel.
- Instabilité de la sélection d'ordres sur des minima AIC plats (démontrée pour le Pétrole SARIMA).
- VECM non estimé : désaccord formel trace/max-eigenvalue, aucune estimation forcée.
- MAPE exclu : les rendements traversent zéro, rendant MAPE indéfini (Hyndman & Koehler).
- Asymétrie DM : le test compare 1-step DL à multi-pas statique ARIMA ; N=25 faible.

14. Conclusion Générale

Cette étude livre un bilan méthodologique honnête : les modèles linéaires et non-linéaires testés ne battent pas significativement le benchmark rendement nul, cohérent avec l'hypothèse d'efficience faible des marchés. Les deux avancées robustes sont la caractérisation de la volatilité conditionnelle (GARCH) et la mise en évidence d'une relation de Granger S&P 500 → Or. L'intégration d'un LLM démontre qu'une assistance IA de haute qualité reste subordonnée à la rigueur quantitative humaine.

Perspectives : modèles asymétriques (EGARCH, GJR), VECM si consensus de cointégration obtenu sur un échantillon étendu, et hybridation GARCH-LSTM pour la volatilité.

Annexe A — Extraits de Code Clés

A.1 — Split chronologique strict (src/split_data.py)

```
split_position = math.floor(len(prices) * 0.90)
train_prices = prices.iloc[:split_position].copy()
test_prices  = prices.iloc[split_position:].copy()
assert train_prices.index.max() < test_prices.index.min()
assert len(train_prices) + len(test_prices) == len(prices)
```

A.2 — Sélection ARIMA avec filtre de convergence (python/arima_model.py)

```
converged_models = selection_df[selection_df['Converged']]
best_idx = converged_models['AIC'].idxmin()
best_order = converged_models.loc[best_idx, 'Order']
```

A.3 — VECM : porte conditionnelle (python/vecm_model.py)

```
valid_cointegration_rank = (1 <= trace_rank < n_assets)
tests_agree = (trace_rank == maxeig_rank)
should_estimate_vecm = (ALLOW_VECM_ESTIMATION
               
;        and tests_agree
               
;        and valid_cointegration_rank)
```

A.4 — Validation walk-forward sans fuite (python/deep_learning_models.py)

```
for fold in range(N_SPLITS):
    val_start = len(scaled_train) - WINDOW_SIZE
    scaler = StandardScaler().fit(train_slice)  # 
pli courant
    model.fit(..., shuffle=False,
             validation_data=v
al_slice,
             callbacks=[EarlyS
topping(...)])
```

Annexe B — Références Bibliographiques

• Box, G. E. P., Jenkins, G. M., Reinsel, G. C. (2015). Time Series Analysis: Forecasting and Control. Wiley.

• Hamilton, J. D. (1994). Time Series Analysis. Princeton University Press.

• Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. Journal of Econometrics, 31(3), 307–327.

• Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. Econometrica, 50(4), 987–1007.

• Johansen, S. (1991). Estimation and hypothesis testing of cointegration vectors in Gaussian vector autoregressive models. Econometrica, 59(6), 1551–1580.

• Diebold, F. X., Mariano, R. S. (1995). Comparing predictive accuracy. Journal of Business & Economic Statistics, 13(3), 253–263.

• Holm, S. (1979). A simple sequentially rejective multiple test procedure. Scandinavian Journal of Statistics, 6(2), 65–70.

• Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. Journal of Econometrics, 160(1), 246–256.

• Hyndman, R. J., Koehler, A. B. (2006). Another look at measures of forecast accuracy. International Journal of Forecasting, 22(4), 679–688.

• Hochreiter, S., Schmidhuber, J. (1997). Long short-term memory. Neural Computation, 9(8), 1735–1780.

Rapport reconstruit le 12 octobre 2026 à partir du PDF original et des artefacts vérifiés du dossier de soumission. Contenu scientifique inchangé ; tables reformatées, figures renumérotées, structure condensée.